Humanités numériques : structuration des données et des documents textuels

E. Rouquette

Cours 4 – 14 février 2024



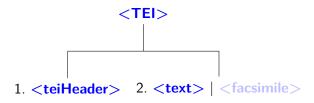
Utiliser la TEI

Pour utiliser un set de balises TEI, il faut déclarer **l'espace de nom TEI** (namespace) dans l'élément racine grâce à une **adresse URI**

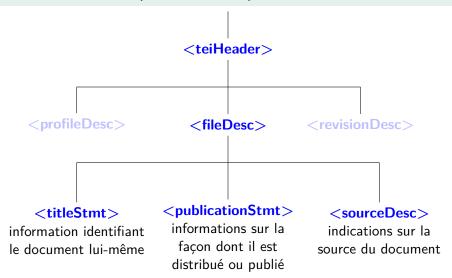
```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
```

Le logiciel oXygen le fait automatiquement lorsque l'on créé un document TEI : Nouveau - modèle du framework - TEI P5 - All

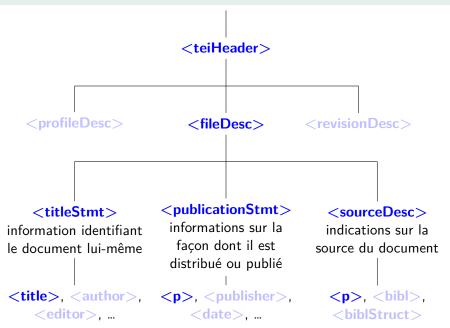
La structure d'un document TEI



Les métadonnées (<teiHeader>)



Les métadonnées (<teiHeader>)



Exemple

```
<teiHeader>
 <fileDesc>
  <titleStmt>
   <title>Thomas Paine: Common sense, a machine-readable

→ transcript</title>

   <respStmt>
    <resp>compiled by</resp>
    <name>.Ion K Adams
   </respStmt>
  </titleStmt>
  <publicationStmt>
  <distributor>Oxford Text Archive</distributor>
  </publicationStmt>
  <sourceDesc>
   <bibl>The complete writings of Thomas Paine, collected and

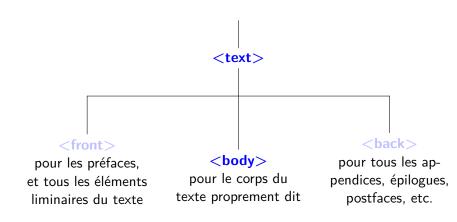
→ edited by Phillip S. Foner (New York, Citadel Press,

→ 1945)</bibl>

  </sourceDesc>
</fileDesc>
</teiHeader>
    (source: TEI Guidelines, The TEI Header and Its Components)
```

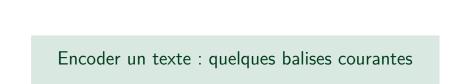
Les éléments obligatoires d'un document TEI – suite

Le corps du texte



Le document TEI minimal

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
<teiHeader>
 <fileDesc>
  <titleStmt>
   <title>Titre du document electronique</title>
  </titleStmt>
  <publicationStmt>
   Informations sur la publication de l'œuvre.
  </publicationStmt>
  <sourceDesc>
   Informations sur la source dont est tirée l'œuvre.
  </sourceDesc>
 </fileDesc>
</teiHeader>
<text>
 <body>
  Le contenu du texte qu'on va encoder
  </body>
 </text>
</TEI>
```



Les divisions du texte

```
<div> Divisions du texte (chapitre, actes, parties, etc). Peut
             être précisé par l'attribut Otype (valeur libre).
<div1>, <div2>, etc : divisions imbriguées
    <head> Titres de section
        paragraphes
        <|> vers
      <|g> « line group » ensemble de vers faisant unité (strophe,
             laisse,...). Peut être précisé par l'attribut Otype
             (valeur libre)
      <ab> « anonymous block » type de séquence textuelle ne
             correspondant pas à ces divisions
```

Les divisions du texte

```
<div> Divisions du texte (chapitre, actes, parties, etc). Peut
             être précisé par l'attribut Otype (valeur libre).
<div1>, <div2>, etc : divisions imbriguées
    <head> Titres de section
        paragraphes
       <|> vers
      <lg> « line group » ensemble de vers faisant unité (strophe,
             laisse,...). Peut être précisé par l'attribut Otype
             (valeur libre)
      <ab> « anonymous block » type de séquence textuelle ne
             correspondant pas à ces divisions
       <s> phrase
      <w> mot
      <pc> ponctuation
       <c> caractère
```

Les noms propres

Deux possibilités :

- 1. <name>, qui peut être précisé avec l'attribut @type (valeurs possibles : "person", "place", ""org"
- <persName>, <placeName>, or <orgName> : nom de personne, nom de lieu, non d'organisation.

La seconde solution est préférée, en particulier quand on veut créer un index.

La balise <persName> peut recevoir l'attribut @type; elle peut avoir des enfants indiquant les composants du nom, par exemple <surname> et <forname>

<rs> : reference string : chaîne de caractères faisant référence à
une entité ou un lieu, même sans contenir de nom propre (par
exemple : l'abbé, lui, etc).

Donner un identifiant à un élément

L'attribut @xml :id

Appartient à l'espace de nom XML

Permet d'attribuer à un élément un identifiant unique auquel il est ensuite possible de se référer dans le cours du document : à des personnes, des lieux, des divisions du texte, des références bibliographiques, etc

L'identifiant peut être attribué entre l'élement <teiHeader> et l'élément <text> , par exemple dans l'élément <standOff>, ou dans le corps du texte.

 ${\bf standOff}$: « Functions as a container element for linked data, contextual information, and stand-off annotations embedded in a TEI document. »

Donner un identifiant à un élément

```
Exemple:
<TET>
<teiHeader>
</teiHeader>
<standOff>
  <listPerson>
   <person>
   <persName xml:id="Dest">Charles-Louis-Joseph Destale/persName>
   </person>
  </listPerson>
 </standOff>
<text>
  <body>
   <rs ref="#Dest">L'abbé</rs> est en manchettes de dentelles
  </body>
 </text>
</TEI>
```

Donner un identifiant à un élément

```
Exemple:
<bibl xml:id="tlk_36">Tolkien (1936)</bibl> tells us
\hookrightarrow that
<quote source="#tlk_36">
<title>Beowulf</title> is in fact so interesting as
   poetry, in places poetry so powerful, that this
    quite overshadows the historical content
</quote>.
(exemple tiré des Guidelines)
```

Exercice 3: encoder en TEI

Encoder de façon simple le début du livre I des *Essais* de Montaigne, édition de 1907, en utilisant l'attribut @xml :id pour les noms propres et les divisions du texte qui vous semblent pertinentes (ne vous préoccupez pas des métadonnées ici)

Le texte à encoder se trouve dans le fichier transcription_Montaigne.txt

Source: https://fr.wikisource.org/wiki/Essais/%C3% A9dition_Michaud,_1907/Livre_I/Chapitre_1

Exercice 3: encoder en TEI

Encoder de façon simple le début du livre I des *Essais* de Montaigne, édition de 1907, en utilisant l'attribut @xml :id pour les noms propres et les divisions du texte qui vous semblent pertinentes (ne vous préoccupez pas des métadonnées ici)

Éléments à utiliser au sein de <body> :

- ► <div1>, <div2>
- ►
- <head>
- <persName>
- <placeName>



La TEI : un cadre modulaire

- La TEI n'est pas un schéma
- La TEI fournit un cadre pour créer son propre schéma
- ► Les *Guidelines* de la TEI sont un guide pour se repérer dans la grammaire TEI
- ► Elles définissent plusieurs centaines de concepts différents, avec les instructions détaillées sur les éléments et les attributs qui peuvent être utilisés pour les représenter et la façon dont ils peuvent être combinés.
- Les concepts sont regroupés en **modules**

http://www.tei-c.org/ Guideline

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

▶ 4 modules obligatoires : → métadonnées et éléments les plus courants

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

- ▶ 4 modules obligatoires : → métadonnées et éléments les plus courants
- ▶ 18 modules additionnels selon le type de texte encodé (poésie, théâtre, dictionnaire, ...) ou le type de données (apparat critique, élément graphique, ...)

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

- ▶ 4 modules obligatoires : → métadonnées et éléments les plus courants
- ▶ 18 modules additionnels selon le type de texte encodé (poésie, théâtre, dictionnaire, ...) ou le type de données (apparat critique, élément graphique, ...)

On peut combiner les éléments de différents modules pour composer son propre schéma (\rightarrow cours 5)



TEI Guidelines PS varion 4.7.0 Last updated on 16th November 2023, revision end/17045. This page generated on 2023-21-16720.03.552

Table des matières des Guidelines. Chaque chapitre couvre un module.

Text Body

- 1 The TEI Infrastructure
- 3 Elements Available in All TEI Documents
- 4 <u>Default Text Structure</u>
- ⊕ 6 <u>Verse</u>
- 7 Performance Texts
- 8 Transcriptions of Speech
- ⊕ 9 Dictionaries
- **±** 10 Manuscript Description

- 13 Names, Dates, People, and Places
- 14 Tables, Formulæ, Graphics, and Notated Music
- 16 Linking, Segmentation, and Alignment
- **±** 18 Feature Structures
- 19 Graphs, Networks, and Trees
- ± 21 Certainty, Precision, and Responsibility
- 22 <u>Documentation Elements</u>

Module name	Formal public identifier	Where defined
analysis	Analysis and Interpretation	17 Simple Analytic Mechanisms
certainty	Certainty and Uncertainty	21 Certainty, Precision, and Responsibility
core	Common Core	3 Elements Available in All TEI Documents
corpus	Metadata for Language Corpora	15 Language Corpora
dictionaries	Print Dictionaries	9 Dictionaries
drama	Performance Texts	7 Performance Texts
figures	Tables, Formulae, Figures	14 Tables, Formulæ, Graphics, and Notated Music
gaiji	Character and Glyph Documentation	5 Characters, Glyphs, and Writing Modes
header	Common Metadata	2 The TEI Header
iso-fs	Feature Structures	18 Feature Structures
linking	Linking, Segmentation, and Alignment	16 Linking, Segmentation, and Alignment
msdescription	Manuscript Description	10 Manuscript Description
namesdates	Names, Dates, People, and Places	13 Names, Dates People, and Places
nets	Graphs, Networks, and Trees	19 Graphs, Networks, and Trees
spoken	Transcribed Speech	8 Transcriptions of Speech
tagdocs	Documentation Elements	22 Documentation Elements
tei	TEI Infrastructure	1 The TEI Infrastructure
textcrit	Text Criticism	12 Critical Apparatus
textstructure	Default Text Structure	4 Default Text Structure
transcr	Transcription of Primary Sources	11 Representation of Primary Sources
verse	Verse	6 Verse

le nom des modules (présenté dans le module 1)

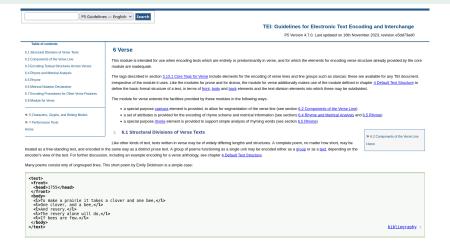
Les modules obligatoires :

- tei définition des classes, macros et types de données
- header en-tête TEI (métadonnées du document)
 - core éléments incontournables pour tout type de document

textstructure éléments de base pour structurer un texte de type livre

Text Body

- 1 The TEI Infrastructure
- 2 The TEI Header
- 3 Elements Available in All TEI Documents
- 4 Default Text Structure



Exemple de description de module : le module verse

Les classes

Les éléments et les attributs sont également organisés en classes de modèle (model class) et classes d'attributs (attribute class)

model.class (Classe de modèle) Regroupe des éléments qui peuvent se trouver au même endroit dans le document + regroupement sémantique att.class (Classe d'attributs) Regroupe des éléments qui partagent les mêmes attributs

Back Matter

- ⊕ Appendix C <u>Elements</u>
- Appendix D Attributes
- Appendix E <u>Datatypes and Other Macros</u>
- ⊕ Appendix F Bibliography
- ⊕ Appendix H <u>Prefatory Notes</u>

Appendix I Colophon

Classes et liste de l'ensemble des éléments définis dans la TEI

Les classes de modèle

Exemple de classes de modèle

- - model.phrase Éléments pouvant apparaître au niveau de la phrase
 - model.nameLike Regroupement sémantique pour les divers types de noms

Les classes de modèle

La liste alphabétique des classes de modèle dans les Guidelines



Les classes de modèle

Exemple : la classe model.quoteLike

model.quoteLike

model.quoteLike groups elements used to directly contain quotations.			
Module	tei — The TEI Infrastructure		
Used by	model.attributable model.msltemPart		
Members	<u>cit quote</u>		

Les classes d'attributs

Exemple de classes d'attributs

```
att.global Attributs pouvant être utilisés avec tout élément.

Contient : @xml :id, @n, @xml :lang, ...
```

att.naming Les attributs communs aux différents éléments qui se réfèrent à des noms de personnes, de lieux, d'organisations, etc. Contient : @key, @ref, @role,

Les classes d'attributs

La liste alphabétique des classes d'attribut dans les Guidelines

att.anchoring att.ascribed att.ascribed.directed
att.breaking
att.calendarSystem att.canonical att.citeStructurePart att.citing att.combinable att.coordinated att.cReferencing
i e e e e e e e e e e e e e e e e e e e
att.damaged_att.datable_att.datable.custom_att.datable.iso_att.datable.w3c_att.datcat_att.declarable_att.declaring_att.deprecated_att.dimensions
att.divLike att.docStatus att.duration att.duration.iso att.duration.w3c
att.edition att.editLike att.enjamb att.entryLike
att.formula att.fragmentable
att.gaijiProp att.global att.global.analytic att.global.change att.global.facs att.global.linking att.global.rendition att.global.responsibility.
at, global, source
1
att.handFeatures
att.identified att.internetMedia att.interpLike
att.lexicographic att.lexicographic.normalized att.linguistic att.locatable
-

Les classes d'attributs

Exemple: la classe d'attribut att.witnessed

att.witnessed				Home B Attribute Classes	
att.witnessed provides attributes used to identify the witnesses supporting a particular reading in a critical apparatus. [12.1 The Apparatus Entry, Readings, and Witnesses]					
Module	textcrit — Critical Apparatus				
Members	lem rdg				
Attributes	@wit ±	(witness or witnesses) contains a space-delimited list of one or more pointers indicating the witnesses which attest to a given reading.			
		Status	Optional		
		Datatype	$1{-}\!$		
		Note	If the apparatus contains readings only for a single witness, this attrib- omitted. This attribute may occur both within an apparatus gathering variant re transcription of an individual witness and within an apparatus gatherin witnesses. Additional descriptions or alternative versions of the sigla referenced content of a find that gleeners.	eadings in the ng readings from different	

Exercice 4 : résoudre un problème d'encodage précis en utilisant les *Guidelines*

Trouver comment encoder une liste de personnages et les indications de lieu au début d'une pièce de théâtre; encoder celles du *Cid*. Le texte à encoder se trouve dans le fichier transcription_Cid.txt (https://fr.wikisource.org/wiki/Le_Cid/%C3%89dition_Ginn/Personnages)

DON FERNAND, premier roi de Castille DONA URRAQUE, infante de Castille DON DIÉGUE, père de don Rodrigue DON GOMÈS, comte de Gormas, père de Chimène DON RODRIGUE, amant de Chimène DON SANCHE, amoureux de Chimène DON ARIA DON ALONSE Gentilshommes castillans. CHIMÈNE, fille de don Gomès LÉONOR, gouvernante de l'Infante ELVIRE, gouvernante de Chimène UN PAGE de l'Infante

Solution

```
<text>
<front>
  <castList>
   <head>ACTEURS</head>
   <castItem>
    <role>DON FERNAND</role>
    <roleDesc>premier roi de Castille</roleDesc>
   </castItem>
   <castItem>
    <role>DONA URRAQUE</role>
    <roleDesc>infante de Castille</roleDesc>
   </castItem>
<!-- et caetera -->
  </castList>
   <set>
    La scène est à Séville
   </set>
</front>
 <body>...</body>
</text>
```

Solution

```
Cas particulier : les rôles regroupés
<castGroup rend="braced">
 <castItem>
  <role>DON ARIA</role>
 </castItem>
 <castItem>
  <role>DON ALONSE</role>
 </castItem>
 <roleDesc>gentilshommes castillans</roleDesc>
</castGroup>
```

Exercice 5

Résoudre un problème précis d'encodage en s'appuyant sur les *Guidelines*

Rechercher dans les *Guidelines* de la TEI des balises et attributs pour remplacer celles que nous avons utilisées dans notre encodage initial du poème «L'Adieu».

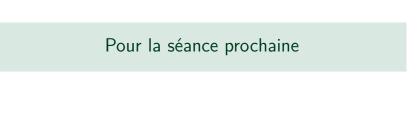
 \rightarrow transformer l'encodage suivant en encodage valide selon le vocabulaire XML-TEI :

```
<titre>L'Adieu</titre>
<poeme>
  <vers rime="A" num="1">J'ai cueilli ce brin de bruyère</vers>
  <vers rime="B" num="2">L'automne est morte souviens-t'en </vers>
  <vers rime="A" num="3">Nous ne nous verrons plus sur terre</vers>
  <vers rime="A" num="4">Odeur du temps brin de bruyère </vers>
  <vers rime="B" num="5">Et souviens-toi que je t'attends</vers>
</poeme>
```

Ne vous préoccupez pas des métadonnées (<teiHeader>).

Solution

```
<text>
 <front>
  <head>L'Adieu</head>
 </front>
 <body>
  <ld><lg rhyme="AABBB"</li>
   | n="1">J'ai cueilli ce brin de bruyère</l>
   <1 n="2"> L'automne est morte souviens-t'en</l>
   <1 n="3">Nous ne nous verrons plus sur terre</l>
   <1 n="4">Odeur du temps brin de bruyère</l>
   <1 n="5">Et souviens-toi que je t'attends</l>
  </lg>
 </body>
</text>
```



Lire dans Qu'est-ce que la Text Encoding Initiative de Lou Burnard les deux chapitres sur « la corne d'abondance de la TEI » et le chapitre « Personnaliser la TEI »

Exercice 6 : Résoudre un problème précis d'encodage en s'appuyant sur les *Guidelines*

- ► Encoder les métadonnées, le titre, les épigraphes et les dix premières entrées de lettre A du *Dictionnaire des idées reçues* de Flaubert.
- ► Le texte à transcrire est dans le fichier transcription_Flaubert.txt
- Source du texte :
 https://fr.wikisource.org/wiki/Dictionnaire_des_
 id%C3%A9es_re%C3%A7ues/Texte_entier