# Humanités numériques : structuration des données et des documents textuels

E. Rouquette

Cours 5 – 28 février 2024

## Tester son encodage TEI

Il est possible de tester la façon dont un texte encodé pourrait être rendu en HTML sur le site TEI-pubisher



https://teipublisher.com/exist/apps/tei-publisher/index.html

→ tester avec l'encodage de l'extrait de Flaubert



Génétique Axée sur la genèse des textes, leur processus de création.

Exemple : Madame Bovary : l'histoire du texte à travers ses brouillons

Génétique Axée sur la genèse des textes, leur processus de création.

Exemple : Madame Bovary : l'histoire du texte à travers ses brouillons

Diplomatique Attention à l'aspect visuel du texte et aux spécificités de graphies.

Exemples : Le Berlin intellectuel des années 1800 : version diplomatique et version de lecture des lettres Montaigne, *Essais* (1ère édition, 1588)

Génétique Axée sur la genèse des textes, leur processus de création.

Exemple : Madame Bovary : l'histoire du texte à travers ses brouillons

Diplomatique Attention à l'aspect visuel du texte et aux spécificités de graphies.

Exemples : Le Berlin intellectuel des années 1800 : version diplomatique et version de lecture des lettres Montaigne, *Essais* (1ère édition, 1588)

Fac-similaire À partir d'images et non de texte Exemple : La Cantilène de Sainte-Eulalie

Génétique Axée sur la genèse des textes, leur processus de création.

Exemple : Madame Bovary : l'histoire du texte à

travers ses brouillons

Diplomatique Attention à l'aspect visuel du texte et aux spécificités de graphies.

Exemples : Le Berlin intellectuel des années 1800 : version diplomatique et version de lecture des lettres

Montaigne, Essais (1ère édition, 1588)

Fac-similaire À partir d'images et non de texte

Exemple : La Cantilène de Sainte-Eulalie

Critique Mise en parallèle des versions d'un texte pour en

révéler les variantes

Exemple : Cicéron, Timaeus

Pour une réflexion épistémologique sur l'édition numérique, voir par exemple :

Frédéric Duval, « Pour des éditions numériques critiques. L'exemple des textes français », *Médiévales*, 73, automne 2017

## La critique textuelle

- Une édition critique compare les manuscrits pour établir le texte original et rendre compte de cette comparaison dans un apparat critique.
- À partir de la comparaison des variantes, on essaie d'établir une généalogie des textes, pour donner ensuite un texte le plus proche possible du texte original (archétype).
- ▶ Plusieurs approches sont possibles : approche dite «Lachmanienne», approche dite «Bédiériste». Voir par exemple J.-B. Camps, Copie, authenticité, originalité dans la philologie et son histoire, Questes, 29 (2015)

## Quelques étapes pour la constitution d'une édition critique

Recension Examen de la tradition d'un texte (manuscrits, *editio princeps*,..)

Collation Alignement des différentes versions, pour relever leurs divergences

Stemma Arbre généalogique d'un écrit ancien indiquant les relations entre divers manuscrits

Un outil de collation automatique avec python : collatex https://collatex.net/demo/

 $\Omega$ : Le petit chat est mort


► A : Le petit chat est malade

- ► A : Le petit chat est malade
- ▶ B : Le petit chat est moche


- ► A : Le petit chat est malade
- ► B : Le petit chat est moche
- ► C : Le petit chien est mort

- ► A : Le petit chat est malade
- ▶ B : Le petit chat est moche
- ► C : Le petit chien est mort
- D : Le petit chien est décédé


- ► A : Le petit chat est malade
- ▶ B : Le petit chat est moche
- C: Le petit chien est mort
- D : Le petit chien est décédé



- ► A : Le petit chat est malade
- ▶ B : Le petit chat est moche
- C: Le petit chien est mort
- D : Le petit chien est décédé



- ► A : Le petit chat est malade
- ▶ B : Le petit chat est moche
- C: Le petit chien est mort
- ► D : Le petit chien est décédé



О	le petit	chat	est	mort
Α	le petit	chat	est	malade
В	le petit	chat	est	moche
С	le petit	chien	est	mort
D	le petit	chien	est	décédé

## Exemple: un vis-à-vis avec LATEX (fichier pdf)

	704	z. Praefatio bibliothecae		
		2. Praefatio bibliothecae		
		(Dim. XII, Sir. II, 1-2)		
	ı.			
		Quicquid ab hebreo stilus Atticus atque Latinus		
		Sumpsit, in hoc totum codice <sup>1</sup> , lector, habes.		
		Quo loca prima tenet <sup>a</sup> Genesis, primordia <sup>3</sup> mundi		
		Diluuiumque canens gestaque magna patrum.		
5		Exodus Aegyptum spoliat, secat aequora rubra,		
		Pandit iter heremi : lympha ibi Lexque datur.		
		Inde sacerdotum gentem Leuiticus ornat		
		Et typica <sup>4</sup> exponit dona sacris typicis.		
		Bella uirosque liber Numeri describit <sup>5</sup> , et actus		
		Quis Moyses fregit idola, stupra <sup>6</sup> , duces.		
		Post repetit Legem, populo benedicit et alma?		
		Iura dat, ac dicto carmine uictor obit.		
		Diuidit hine proprio terram Nauegius heros		
		Libro, deletis urbibus atque locis.		
1		Pridem iudicibus quis et ordo cucurrit et actus,		
		Continuante stilo concinit inde sequens.		
		Moxque sedent quae Ruth, Moabitis <sup>8</sup> femina, gessit,		
		Clara piis meritis, clara nepote pio.		
		Psalmicanique <sup>9</sup> actus et iniqui gesta Saulis		
		Prime** sequensque** liber, hinc**, Samuhelis, habes*3.		
		Tertius et™ quartus, Malachim quis nomen inhesit™,		
		Regum hebreorum ex ordine gesta canunt.		
		Hine <sup>16</sup> sedet <sup>17</sup> Esaias Christum de uirgine nasci		
		Qui canit, et gentes ad pia iura uocat.		

To me at 1977, Profession Substances for constraint D<sub>c</sub> as presented upon superant companies for the control state of the control stat

## Diss. XII, Sie II, 1-2 2. Préface à la Bible

(Dûm, XLL Sir, IL 1-2)

Tout ce qu'à l'hébreu les stylets grec et latin Ont emorunté, tu l'as en entier dans ce livre, lecteur. La Genèse y occupe la première place, chantant les premiers moments du monde\*, Le Déluge<sup>b</sup> et les hauts faits des Pères\*. L'Exode dépouille l'Égypte<sup>d</sup>, divise la mer Rouge<sup>e</sup>, Ouvre le chemin du désert<sup>f</sup> : là sont données l'eau et la Loi<sup>g</sup>. Le Lévitique ensuite pare la lignée des prêtresh Et expose les offrandes typologiques pour les sacrifices typologiques<sup>i</sup>. Le livre des Nombres décrit les guerres et les hommes, et les actes Par lesquels Moïse brisa les idoles, les impuretés, les chefs. Après quoi, il va chercher la Loi, bénit le peuple, et lui donne Les doux commandements<sup>1</sup>, puis meurt, victorieux, après avoir dit un cantique<sup>k</sup>. Le héros fils de Nún' partage ensuite dans son livre la terre Après la destruction des villes et des campagnes<sup>as</sup>. Le livre suivant chante ensuite, sans que s'arrête son stylet, L'ordre et les actes des juges d'autrefois. Se trouve ensuite ce que fit Ruth, la Moabite, Illustre pour ses pieux mérites, illustre pour sa pieuse descendance<sup>a,a</sup>. Puis ce sont les actes du Psalmiste<sup>3</sup> et les faits de l'inique Saül Oue vous contenez, premier et second livres de Samuel. Ses troisième et quatrième livres, auxquels est attaché le nom de Malachim<sup>4</sup>, Chantent dans l'ordre les faits des rois des hébreux. Puis se trouve Isaïe, qui chante que le Christ naît de la Vierre°


\*Gri-s \*Gri-s \*Gri-s \*Gri-sp \*Ery, 22 \*Eriq, 19-31 \*Eriy, 22 \*Eriy, 19-31 \*Eriy, 19

Et qui appelle les nations à suivre les pieux commandements.

'Somé. "Ruth donna naissance à Obed, père de Jessé, père de David, de qui descend Jésus. "David, à qui sont attribués les Pasames. "Mot qui signifie « des rois » en hébreux, selon Isidore de Séville, Etymologies,

11 Notine, Epistolae, 53, 8: « Malachim, id est tertius et quartus Regum liber » 11 hidore de Séville, Etymologiae, VI, 11: « Malachim liber posinde appellatur, eo quod neges Indas et insideliticas gretis gestuque cocum per ordinem diagreta temporum » 23 Jérôme, Epistolae, 53, 8: « non prophetium milii sidetur tenses, sed erungelium »

## Une collation manuelle...



# Encodage XML

```
<1>Quo loca prima <app>
  <rdg type="source"
  wit="#AM #reglat2078 #montpellier306 #angel1515,
  #gall197 #clm18375 #D #N #Co #Si">
 tenet</rds>
  <rdg wit="#8093 #2832">-nent</rds>
</app> Genesis, <app>
  <rdg type="source" wit="AM #reglat2078 #montpellier306,</pre>
 #angel1515 #gall197 #clm18375 #D #N #Co #Si">
 primordia</rdg>
  <rdg wit="#8093 #2832">-iam</rdg>
</app> mundi
</1>
```

# Transformation vers LATEX du texte encodé en XML : XSLT

## Résultat pdf : l'apparat

# Le module textcrit pour les édition critiques

Module pour produire des apparats critiques : Critical Apparatus  $\rightarrow$  description d'éléments qui permettent de produire des apparats critiques pour des éditions scientifiques

# La méthode d'encodage choisie (→ métadonnées)

`Les deux méthodes d'encodage des variantes

Méthode d'encodage à indiquer dans <encodingDesc> :

**1. double-end point** : le lemme est indiqué dans le texte directement et les variantes à part

```
<variantEncoding method="double-end-point"
location="internal"/>
```

**2. Parallel segmentation** : toutes les variantes sont signalées au fil du texte.

```
<variantEncoding method="parallel-segmentation"
location="internal"/>
```

ightarrow celle que nous allons utiliser. Elle permet d'obtenir un apparat positif, ou encore d'extraire le texte complet de n'importe quel témoin.

# La recension des témoins (→ métadonnées)

Déclaration des témoins dans l'élément <sourceDesc> avec les éléments tWit> et <witness>

```
<sourceDesc>
  stWit>
    <witness xml:id="A">
        Paris, BnF, Latin 8093
    </witness>
    <witness xml:id="B">
        Paris, BnF, Latin 2832
        </witness>
        </listWit>
        </sourceDesc>
```

# Exercice : Encoder un court texte avec apparat critique 1/Recenser les témoins

Nous allons encoder en vue d'une édition critique le  $Carmen\ XX$  de Sidoine Apollinaire.

- 2. Entrer dans le <sourceDesc> la liste des manuscrits fournies dans le fichier transcription\_Sidoine.txt

**nb**: Nous nous appuyons pour cet exercice sur l'édition d'André Loyen (Les Belles Lettres, 1961).

## Encoder une variante simple

#### **Encoder les variantes:**

```
<app> Une entrée dans l'apparat critique (→un lieu variant). Doit contenir au moins une leçon
  <lem> Le lemme (la leçon choisie)
  <rdg> Une leçon, à l'intérieur d'une entrée dans l'apparat
  </dg>

    <rdgGrp> Regroupe deux leçons ou plus qui sont perçues comme ayant une relation (exemple : des variantes orthographiques d'un même mot)
```

#### Indiquer les témoins :

```
<rdg wit="#Exemple">...</rdg>
```

## Encoder une variante simple

```
Exemple :
Le petit <app>
    <lem wit="#A #B">chat</lem>
        <rdg wit="#C #D">chien</rdg>
    </app>    est mort
```

# Exercice : Encoder un court texte avec apparat critique 2/Encoder les variantes

- ► Encoder le texte de Sidoine avec <head> et <1>
- Encoder les variantes du texte avec les éléments <app>, <lem>, <rdg> et l'attribut @wit
- → Lorsque vous tapez l'attribut @wit, oXygen vous propose comme valeur chaque témoin présent dans t\u00e4tit>, en indiquant quel témoin a déjà été noté
  - ► Tester votre solution sur le site TEI Critical Apparatus Toolbox (http://teicat.huma-num.fr/)



## Ajouter des informations

```
Quelques attributs possibles au sein des éléments <lem> ou <rdg> :
      Otype Type de variante. Exemple de valeur : "substantive",
             "semantic", "orthographic", "omission"
     Ohand main responsable de la variante. Renvoie à un
             @xml :id défini dans un <handNote> lui-même
             contenu dans <handDesc>.
             Exemple: <handNote xml:id="scribe1">Premier
             scribe</handNote>
      Oresp référence à l'xml :id du responsable (l'auteur de la
             correction.)
      Ocert le degré de certitude ("high", "low")
       etc...
```

## Informations sur les témoins

</app> est mort

```
<witDetail> Détails sur les témoins
<witStart>, <witEnd> Témoin fragmentaire
<a href="mailto:</a> <a href="mailto:lacunaStart/">lacunaStart/</a>, <a href="mailto:lacunaStart/">lacunaStart/</a>, <a href="mailto:lacunaEnd/">lacunaStart/</a>, <a href="mailto:lacunaEnd/">lacunaEnd/</a> Début et fin de lacune d'un
                  manuscrit
Exemple:
Le petit <app>
 <lem wit="#A #B">chat</lem>
 <rdg wit="#C #D">chien</rds>
 <rdg wit="E" type="omission"/>
 <witDetail wit="#E">Le mot a été remplacé par un

→ dessin
/witDetail>
```

Exercice: Encoder un court texte avec apparat critique 3/Encoder les variantes (fin)

Encoder les variantes du titre, en indiquant l'omission au moyen de l'attribut <u>@type</u> dans une balise <rdg/> auto-fermante

## Aller plus loin

```
https://teibyexample.org/exist/tutorials/TBED07v00.
htm#apparatus
http://developpements.enc.sorbonne.fr/diple/schema/
witness/
```

## Autres outils pour des éditions scientifiques :

### Le module transcr pour les facs-similés

Module pour représenter les sources primaires : Representation of Primary Sources

- indications sur la matérialité des documents
- $\blacktriangleright$  permet d'encoder les images sources encodées pour un alignement texte/image  $\rightarrow$  combiner fac-similé et transcription

Exemple: manuscrit interactif sur le site de l'EnC: http://theleme.enc.sorbonne.fr/dossiers/vue97.php

Outil pour annoter une image en TEI: http://teicat.huma-num.fr/zoner/index.php#catList

## Autres outils pour des éditions scientifiques :

#### Au sein du module core

- $<\!lb/\!>, <\!cb/\!>, <\!pb/\!>$  Indiquer un début de ligne, de page ou de colonne
  - <choice> Traiter une même donnée de plusieurs manières :
    <orig>/<reg> Version originale/version régularisée
    <sic>/<corr> Version fautive/version corrigée
    <abbr>/<expan> Abréviation/résolution de
    l'abréviation
    - <add> (ajout) contient un ajout
    - <del> (suppression) contient une séquence supprimée ou indiquée comme telle
    - <gap> (omission) omission pour raison éditoriale ou pour toute autre raison
      - <hi> (mise en évidence) désigne une séquence mise en évidence d'un point de vue graphique
  - <unclear> (incertain) contient une séquence difficile à transcrire

## Autres outils pour des éditions scientifiques :

#### Encoder des caractères spécifiques

#### Les entités

Commencent par le signe & et se terminent par ; Permettent d'encoder des objets spécifiques, sous forme d'alias :

des caractères spéciaux (caractères réservés en XML) :

```
< < &amp; &
```

 des caractères que l'on déclare dans une DTD et qu'il sera possible d'utiliser dans le document XML

```
Liste des entités : https://en.wikipedia.org/wiki/List_of_
XML_and_HTML_character_entity_references
```

## Autres outils pour des éditions scientifiques :

#### Encoder des caractères spécifiques

#### Exemple d'utilisation d'entité

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE TEI ∫
<!ENTITY s-long "f">
1>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>...</teiHeader>
 <text>
  <body>
   Le &s-long; ene&s-long; chal du roy
  </body>
 </text>
</TEI>
```

Voir le fichier exemple-tei.xml (à tester sur TEI publisher)

## Autres outils pour des éditions scientifiques :

#### Encoder des caractères spécifiques

#### Outils pour encoder les caractères médiévaux

MUFI Medieval Unicode Font Initiative  $\rightarrow$  documentation sur l'encodage unicode des caractères médiévaux

module Gaiji : Characters, Glyphs, and Writing Modes → permet l'utilisation des caractères autres que les standards de l'alphabet latin

Personnaliser la TEI : schémas et ODD

#### Les modèles TEI

Aucun projet n'utilise toutes les balises possibles. Il existe des modèles (schémas) sélectionnant un certain nombre d'éléments. Exemple :

```
tei_lite Couvre les besoins de 90% des utilisateurs
tei_corpus pour les corpus linguistiques
    tei_ms pour la description de manuscrits
tei_drama pour les corpus dramatiques
```

Toutefois, ces schémas ne conviennent pas toujours. → Il est possible de **générer son propre schéma TEI** avec **Roma**: https://roma.tei-c.org/. Permet aussi documenter son travail, de préciser ses choix.

#### Les ODD

#### One Document Does it all

- Un ODD est un fichier XML
- Ce fichier permet de produire à la fois un schéma, lisible par la machine, et une documentation, lisible par l'humain, des balises et attributs contenu dans le schéma et de leurs relations
- → validation du document, guidage de l'encodage

#### Les ODD

#### One Document Does it all

#### Les ODD

#### One Document Does it all

#### Produire un ODD avec ROMA

```
https://roma.tei-c.org/
```

#### Choix de départ

- ► Modèle TEI existant. Exemples :
  - ► TEI-all (on enlèvera des éléments)
  - ► TEI minimal (on ajoutera des éléments)
- ODD vierge
- ODD déjà existant

À partir de ce point de départ, il est possible d'ajouter des éléments un à un, ou de sélectionner tous les éléments d'un module

## Exercice: Produire son ODD avec ROMA (1)

 Créer avec oXygen un document utilisant comme schéma le modèle TEI-drama :

Nouveau - modèle du framework - TEI P5 - Drama

- Y coller l'encodage des rôles du Cid (cours n.4 : fichier solution\_Cid.xml
- Repérer le problème : l'attribut @rend n'est pas accepté dans l'élément <castGroup rend="braced">
- ightarrow Nous allons produire étape par étape un ODD ajoutant simplement au module drama l'attribut @rend pour l'élément <castGroup>

## Exercice: Produire son ODD avec ROMA (1)

## **Créer un ODD avec Roma à partir de TEI-drama** (lui donner un nom et un identifiant). Puis :

- cliquer sur l'élément <castGroup> → essayer de lui ajouter l'attribut @rend : celui-ci ne fait pas partie de la customization.
- 2. Chercher la classe d'attribut dans laquelle se trouve @rend : global.rendition. Rajouter la classe.
- 3. Au sein de cette classe, ne sélectionner que l'attribut @rend
- Dans l'élément <castGroup>, rajouter @rend et l'éditer : choisir « Default (Optional) »

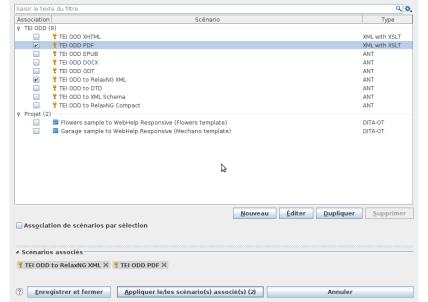
### Associer l'ODD au document XML

- à la fin de l'édition de l'ODD, télécharger le résultat : Download- Customization as ODD
- 2. mettre l'ODD dans le dossier où se trouve le document XML
- 3. ouvrir l'ODD dans oXygen
- cliquer sur la clé à molette pour « Configurer le scénario de transformation »



### Associer l'ODD au document XML

#### Une fenêtre s'ouvre :



### Associer I'ODD au document XML

- Sélectionner « TEI ODD to RelaxNG XML »
- ► (et «TEI ODD to PDF» pour produire la documentation)
- cliquer sur « Appliquer le/les scenarios associé(s) »
- On obtient un dossier out dans lequel se trouve le schéma généré; l'associer à son fichier XML au moyen de l'épingle rouge



ightarrow il est désormais possible d'ajouter l'attribut @rend

# Exercice pour la semaine prochaine : : Produire son ODD avec ROMA (2) - partir du modèle minimal

## Créer un ODD pour générer un schéma convenant à notre encodage du Dictionnaire des idées reçues de Flaubert

- ▶ Dans Roma, partir du modèle « TEI minimal ». Donnez un titre et un identifiant à votre personnalisation
- Ajouter les différents éléments utilisés pour l'encodage du Dictionnaire
- Une fois votre schéma obtenu, vérifiez-le (si vous l'associez au document XML, celui-ci doit-être valide)
- Suite de l'exercice : encoder la fin de la première partie du dictionnaire avec ce schéma – Voyez si vous devez compléter votre schéma

## Exercice pour la semaine prochaine : : Produire son ODD avec ROMA (2) - partir du modèle minimal

# Créer un ODD pour générer un schéma convenant à notre encodage du Dictionnaire des idées reçues de Flaubert Conseils pour cet exercice

 Partir du mode « grille » dans l'édition du document XML pour repérer tous les éléments utilisés

```
Texte Grille Auteur
```

- ► Testez d'abord votre schéma en ayant ajouté seulement des éléments — pour repérer s'il faut ou non ajouter des attributs
- Pensez à chercher par modules pour les éléments propres au dictionnaire
- Faites des exports intermédiaires sous forme d'ODD pour éviter de perdre votre travail